

Mémoire de fin d'études
Pour l'obtention du diplôme d'Ingénieur d'État en Informatique
Option : Systèmes Informatiques

Création d'un corpus de l'aphasie de Broca et
développement d'un système Speech-to-speech de
réhabilitation de la parole

Réalisé par :
BELGOUMRI Mohammed
Djameleddine
im_belgoumri@esi.dz

Encadré par :
Pr. SMAILI Kamel
smaili@loria.fr
Dr. LANGLOIS David
david.langlois@loria.fr
Dr. ZAKARIA Chahnez
c_zakaria@esi.dz

Table des matières

Page de garde	i
Table des matières	i
Table des figures	ii
Algorithmes et extraits de code	iii
Sigles et abréviations	iv
1 Tests et résultats	1
1.1 Erreurs générées	1
1.2 Corpus créé	3
1.3 Entraînement du modèle	5
1.4 Réglage des hyper-paramètres	7
Bibliographie	9
A Dépendances et bibliothèques	10

Table des figures

1.1	Fréquences des catégories d’erreurs	1
1.2	Perplexité des phrases du corpus par rapport à différents modèles de langue.	3
1.3	Évolution des métriques au cours de l’entraînement.	6
1.4	Résultats de la recherche Bayésienne des hyperparamètres.	7

Algorithmes et extraits de code

1.1	Génération des erreurs pour un mot	2
1.2	Calcul de la perplexité avec le modèle <code>gpt-fr-cased-base</code>	4
1.3	Calcul du score BLEU sur le corpus de validation.	5

Sigles et abréviations

BLEU bilingual evaluation understudy

GPT generative pre-trained transformer

Chapitre 1

Tests et résultats

Le premier chapitre de cette partie est consacré à la présentation de la conception de notre solution. Le deuxième résume les étapes de sa réalisation. Dans ce chapitre, nous présentons les résultats obtenus en les analysant et en les commentant.

1.1 Erreurs générées

Parmi les erreurs générées par chatGPT, celles qui ressemblent le plus à des erreurs humaines ont été manuellement sélectionnées. Le résultat de cette sélection est une liste de 217 mots avec une moyenne de 5 erreurs retenues par mot (1104 erreurs en termes absolus). Ces erreurs ont été analysées et classées en 4 catégories :

- des suppressions : de lettres ou de syllabes,
- des ajouts : de lettres ou de syllabes,
- des substitutions : de lettres ou de syllabes,
- des transpositions : de lettres ou de syllabes.




FIGURE 1.1 – Fréquences des catégories d'erreurs

Les fréquences de ces erreurs (pour les 32 premiers mots qui ont 327 modifications) sont présentées dans la Figure 1.1. Sur la base de ces fréquences, nous avons créé une

fonction qui génère pour un mot donné, des erreurs qui suivent les mêmes fréquences (voir le code 1.1).

```
1 def corrupt_word(  
2     word,  
3     p_remove=0.51,  
4     p_substitute=0.25,  
5     p_transpose=0.13,  
6     p_insert=0.11,  
7     p_skip=0.5,  
8     all_syllables=None,  
9 ):  
10     from random import seed, randint, random  
11     from hyphen import Hyphenator  
12  
13     hyphenator = Hyphenator("fr_FR")  
14     syls = hyphenator.syllables(word)  
15  
16     # skip words that are too short  
17     if len(syls) < 3:  
18         return word  
19  
20     # skip all words with probability p_skip  
21     if random() < p_skip:  
22         return word  
23  
24     # remove a syllable with probability p_remove  
25     if random() < p_remove:  
26         idx = randint(0, len(syls) - 1)  
27         del syls[idx]  
28  
29     # substitute a syllable with probability p_substitute  
30     if random() < p_substitute:  
31         idx1 = randint(0, len(syls) - 1)  
32         syls[idx1] = choice(all_syllables)  
33  
34     # transpose two syllables with probability p_transpose  
35     if random() < p_transpose:  
36         idx1 = randint(0, len(syls) - 1)  
37         idx2 = randint(0, len(syls) - 1)  
38         syls[idx1], syls[idx2] = syls[idx2], syls[idx1]  
39  
40     # insert a syllable with probability p_insert  
41     if random() < p_insert:  
42         idx = randint(0, len(syls) - 1)  
43         syls.insert(idx, choice(all_syllables))  
44     return "".join(syls)
```

Extrait de code 1.1 Génération des erreurs pour un mot

Les erreurs générées par cette fonction sont similaires aux erreurs générées par chatGPT (par exemple, maintenant → temain | tenant, entendu → enten | tendu | tenendu.). Cependant, certaines parmi elles ne sont pas prononçables (par exemple, maintenant → nantmain, simplement → mentple). Pour cette raison, nous avons décidé de ne pas les utiliser dans le corpus. Cela étant dit, il nous paraît intéressant d’explorer des méthodes de filtrage de ces erreurs. Si réussies, elles permettent de générer des erreurs plus rapidement et plus facilement que par chatGPT.

1.2 Corpus créé

Après avoir construit le corpus parallèle en suivant la démarche décrite dans ????, il est nécessaire d'évaluer sa qualité. Pour cela, nous avons choisi deux métriques : bilingual evaluation understudy (BLEU) (voir Section ??) et la perplexité.

1.2.1 Perplexité

La perplexité est une mesure de la qualité d'un modèle de langue par rapport à un corpus. Si la qualité du modèle est connue (et bonne), la perplexité est une mesure de la qualité du corpus. La perplexité du corpus \mathcal{C} par rapport au modèle de langue \mathcal{M} est définie comme la moyenne géométrique des probabilités des phrases du corpus (voir l'équation 1.1).

$$\text{perplexité}(\mathcal{C}, \mathcal{M}) = \prod_{s \in \mathcal{C}} \mathcal{M}(s)^{-\frac{1}{|\mathcal{C}|}} \quad (1.1)$$

En prenant le logarithme de la perplexité, on retrouve l'entropie croisée de la loi de probabilité donnée par \mathcal{M} et celle induite par \mathcal{C} ¹. Elle mesure ainsi la dissimilarité entre ces deux lois (voir Section ??). La perplexité des phrases générées (pour simuler l'aphasie de Broca) est une mesure de la dissimilarité entre ses phrases et le français courant.




FIGURE 1.2 – Perplexité des phrases du corpus par rapport à différents modèles de langue.

Pour calculer la perplexité, nous avons utilisé quatre modèles de langage basés sur GPT-2 et hébergés sur Hugging Face Hub :

1. À une constante multiplicative dépendante de la base du logarithme près

	french	aphasia
gpt-2	392.07	566.07
gpt-2-large	182.20	417.30
gpt-fr-cased-small	147.84	1357.31
gpt-fr-cased-base	123.93	1023.12

TABLE 1.1 – Perplexité des phrases du corpus par rapport à différents modèles de langue.

- `gpt2` : ce modèle compte 124 M de paramètres et a été entraîné sur 40 Go de texte en plusieurs langues.
- `gpt2-large` : ce modèle compte 774 M de paramètres et a été entraîné sur le même corpus que `gpt2`.
- `gpt-fr-cased-small` : ce modèle compte 124 M de paramètres et a été entraîné sur un corpus de textes en français d’une taille non précisée.
- `gpt-fr-cased-base` : ce modèle compte 1.017 G de paramètres et a été entraîné sur le même corpus que `gpt-fr-cased-small`.

Le code utilisé pour calculer la perplexité est donné par l’Extrait de code 1.2. Ce code a été exécuté sur Google Colaboratory avec une instance GPU munie de 16 Go de mémoire vive.

Les résultats sont donnés par Figure 1.2 et Table 1.1. On y observe que tous les modèles attribuent une perplexité plus faible aux phrases en français qu’à celles qui simulent l’aphasie de Broca. On note également que cette différence est plus prononcée pour les modèles entraînés sur des textes en français.

```

1 import pandas as pd
2 import evaluate
3
4 # Load perplexity metric
5 perplexity = evaluate.load("perplexity", module_type="measurement")
6
7 # Load data
8 df = pd.read_csv("val.csv")
9 fr = df.french.tolist()
10 aph = df.aphasia.tolist()
11
12 # Compute perplexities
13 fr = perplexity.compute(
14     model_id='asi/gpt-fr-cased-base',
15     add_start_token=False,
16     data=fr
17 )
18 aph = perplexity.compute(
19     model_id='asi/gpt-fr-cased-base',
20     add_start_token=False,
21     data=aph
22 )
23
24 print(f'{fr["mean_perplexity"]:.2f}, {aph["mean_perplexity"]:.2f}')

```

Extrait de code 1.2 Calcul de la perplexité avec le modèle `gpt-fr-cased-base`.

Les différences données par ces derniers sont compatibles avec les résultats obtenus par (GHUMMAN, 2021) avec des transcriptions de patients aphasiques et un groupe de contrôle. Il est raisonnable d'en conclure que les phrases générées sont similaires à celles produites dans le cas d'une aphasie de Broca.

1.2.2 Score BLEU

Le problème avec l'utilisation de la perplexité pour mesurer la différence entre les phrases générées et le langage ordinaire, est qu'elle ne prend pas en compte la relation entre une phrase aphasique et la phrase correcte qui lui correspond. Elle traite les deux corpus comme étant indépendants. BLEU est une métrique qui prend en compte cette relation (voire Section ??). En prenant la moyenne des scores BLEU de chaque couple de phrases dans le corpus parallèle, nous obtenons un seul nombre qui mesure la similarité entre les deux parties du corpus.

L'Extrait de code 1.3 donne le code utilisé pour calculer le score BLEU. La fonction `bleu_score` de `torchmetrics` prend en entrée une liste de phrases qui représentent les traductions candidates (dans notre cas, les phrases aphasiques) et une liste de listes de phrases qui représentent les traductions de référence (dans notre cas, les phrases en français). L'exécution de ce code donne un score BLEU de 62.72% sur le corpus de validation.

```
1 import pandas as pd
2 from torchmetrics.functional import bleu_score
3
4 df = pd.read_csv("val.csv")
5
6 aphasia = df.aphasia.to_list()
7 french = df.french.tolist()
8
9 french = [[s] for s in french]
10 score = bleu_score(aphasia, french) * 100
11 print(f"{score:.2f}%")
```

Extrait de code 1.3 Calcul du score BLEU sur le corpus de validation.

1.3 Entraînement du modèle

Tous les tests présentés dans le reste de ce chapitre ont été effectués sur un ordinateur portable équipé d'un processeur Intel Core i9-8950HK et d'une carte graphique NVIDIA GeForce GTX 1050 Ti. Cette machine se dispose de 32 Go de mémoire vive et de 4 Go de mémoire vidéo. Le système d'exploitation est Ubuntu 20.04 LTS, la version de Python utilisée est 3.10.6 et celle de CUDA est 11.6.124.

1.3.1 Choix des hyperparamètres

Pour notre premier test, nous avons entraîné le modèle pour 8 époques (cela a pris 58 min 25 s). Les hyperparamètres ont été choisis comme suit :

- Dimension de plongement : 64
- Dimension de la couche cachée : 64
- Taux d'apprentissage : 3×10^{-4}
- Dropout : 0.1
- Nombre de couches de l'encodeur/décodeur : 3
- Nombre de têtes d'attention : 4
- Norme maximale des plongements : 1
- Taille de lot : 256
- Norme maximale du gradient : 1
- Coefficient de régularisation L_2 : 10^{-4}
- Nombre de processus pour le chargement des données : 4

1.3.2 Résultats

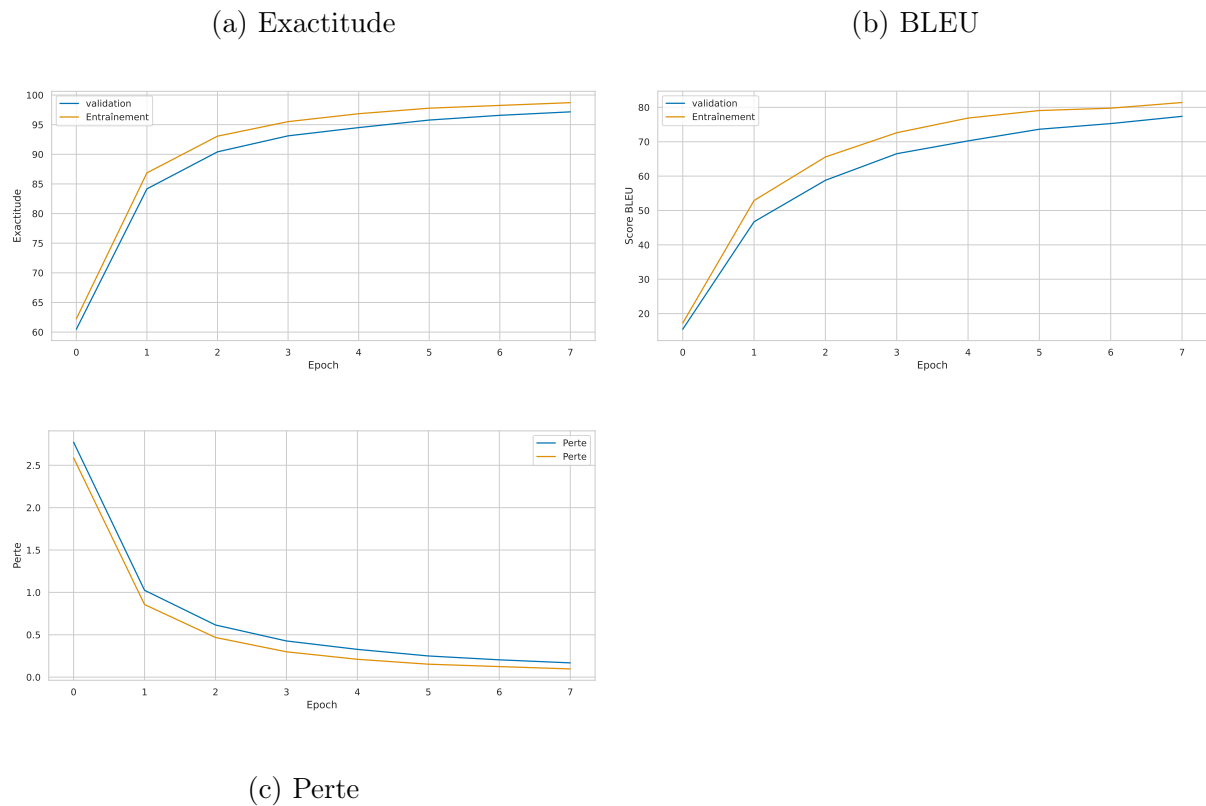


FIGURE 1.3 – Évolution des métriques au cours de l'entraînement.

Pour chaque époque, nous avons calculé la moyenne de la fonction de perte, de l'exactitude et du score BLEU sur le corpus de validation et sur le corpus d'entraînement. Les

résultats sont présentés dans la Figure 1.3. Au bout de 8 époques, la perte sur le corpus d’entraînement est de 0.09. L’exactitude est de 98.71% et le score BLEU est de 81.41%.

Les résultats sur le corpus de validation sont comparables. Les mêmes métriques valent respectivement 0.16, 97.16% et 77.38%. Cela suggère que le modèle ne sur-apprend pas et qu’il est capable de généraliser. On note également que les pentes des trois courbes ne sont pas négligeables. Il est donc probable que le modèle puisse encore s’améliorer en augmentant le nombre d’époques.

1.4 Réglage des hyper-paramètres

Les résultats présentés dans Section 1.3.2 sont satisfaisants. Il n’est donc pas strictement nécessaire d’effectuer un réglage des hyperparamètres. Cependant, il est possible en le faisant d’obtenir des résultats comparables en moins d’époques ou avec un modèle plus petit. Pour cette raison, nous avons décidé de l’entamer.

1.4.1 Configuration

Nous avons fait le choix de restreindre la portée de ce réglage à deux hyperparamètres : le taux d’apprentissage (η ou **lr**) et le (**dropout**). Nous avons opté pour une recherche Bayésienne avec des lois log-uniformes sur les intervalles $[10^{-5}, 10^{-1}]$ et $[0.1, 0.5]$ respectivement. Les autres hyperparamètres ont été fixés à leurs valeurs données dans Section 1.3.1.

Pour chaque combinaison de **lr** et **dropout**, nous avons entraîné le modèle pendant 2 époques. L’objectif de la recherche est de maximiser le score BLEU sur le corpus de validation. Nous avons limité le nombre d’essais à 20.

1.4.2 Résultats

Les 20 essais ont été effectués en 2h 17m 13s 11ms. Les résultats sont présentés dans Figure 1.4. La figure en question est une visualisation en coordonnées parallèles des ré-




FIGURE 1.4 – Résultats de la recherche Bayésienne des hyperparamètres.

sultats. L’axe de gauche représente la valeur de **dropout** sur une échelle linéaire, celui du milieu la valeur de **lr** sur une échelle logarithmique et celui de droite le score BLEU sur une échelle de 0 à 100. Un essai est représenté par une courbe qui relie les 3 points correspondants sur les 3 axes. La couleur de la courbe indique le score BLEU associé. Elle est interpolée entre le violet (0%) et l’orange (100%). Les mêmes informations sont présentes dans Table 1.2 sous forme numérique.

dropout	0.26	0.16	0.32	0.19	0.10	0.10	0.11	0.11	0.50	0.12	0.11	0.12	0.11	0.10	0.10	0.14	0.27	0.15	0.20	0.43
lr (\log_{10})	-4.31	-1.74	-2.12	-3.48	-2.73	-2.73	-2.92	-1.06	-4.96	-2.90	-2.79	-2.70	-3.52	-2.20	-2.93	-2.99	-1.88	-3.11	-4.90	-1.86
val/bleu (%)	0.00	0.00	5.39	37.15	68.80	70.37	67.66	0.00	0.00	69.37	68.68	67.19	42.63	54.09	68.49	65.85	2.55	60.32	0.00	1.26

TABLE 1.2 – Résultats de la recherche Bayésienne des hyperparamètres.

On observe sur la figure un regroupement des lignes oranges (les meilleurs essais) dans la région qui correspond à **dropout** $\in [0.1, 0.15]$ et $\eta \approx 10^{-3}$. Cela est aussi apparent sur le tableau. Une analyse factorielle sur les essais effectués nous permet d’estimer l’importance

	Importance	Corrélation
dropout	63.9%	- 0.899
lr	36.1%	- 0.647

TABLE 1.3 – Importance et corrélation des hyperparamètres.

des hyperparamètres ainsi que leurs corrélations avec le score BLEU. Ils sont tous deux négativement corrélés avec ce dernier. Le **dropout** est le plus important entre les deux (voir Table 1.3). La meilleure valeur du score BLEU est obtenue avec **dropout** ≈ 0.101599 et $\eta \approx 0.0018488801$. Pour cette valeur, le score BLEU sur le corpus de validation est de 70.37% après 2 époques.

Bibliographie

GHUMMAN, N. S. (2021). *Training and Probing Language Models for Discerning between Speech of People with Aphasia and Healthy Controls* (thèse de doct.). University of Georgia.

Annexe A

Dépendances et bibliothèques

```
lightning==2.0.2
torch==2.0.0
pytorch_memlab==0.2.4
PyYAML==6.0
tokenizers==0.13.3
torchdata==0.6.0
torchmetrics==0.11.4
torchtext==0.15.1
torchview==0.2.6
tqdm==4.64.1
beautifulsoup4==4.11.1
openai==0.27.2
pandas==1.5.3
PyHyphen==4.0.3
python-dotenv==1.0.0
Requests==2.30.0
scikit_learn==1.2.0
tokenizers==0.13.3
tqdm==4.64.1
evaluate==0.4.0
```