

Mémoire de fin d'études  
Pour l'obtention du diplôme d'Ingénieur d'État en Informatique  
Option : Systèmes Informatiques

---

Création d'un corpus de l'aphasie de Broca et  
développement d'un système Speech-to-speech de  
réhabilitation de la parole

---

Réalisé par :  
BELGOUMRI Mohammed  
Djameleddine  
[im\\_belgoumri@esi.dz](mailto:im_belgoumri@esi.dz)

Encadré par :  
Pr. SMAILI Kamel  
[smaili@loria.fr](mailto:smaili@loria.fr)  
Dr. LANGLOIS David  
[david.langlois@loria.fr](mailto:david.langlois@loria.fr)  
Dr. ZAKARIA Chahnez  
[c\\_zakaria@esi.dz](mailto:c_zakaria@esi.dz)

## Résumé

L'aphasie est un trouble de langage qui résulte d'une lésion cérébrale (typiquement suite à un AVC). L'aphasie de Broca est une déficience de la production du langage causée par une lésion dans l'aire de Broca, une région du lobe frontal gauche du cerveau, responsable de la production de la parole. Une personne atteinte d'aphasie de Broca peut avoir des difficultés à articuler les mots et les phrases. Cependant, elle peut en général comprendre ce qui est dit. L'aphasie de Broca est associée à une diminution de la qualité de vie et à une augmentation du risque de dépression et de tentative de suicide.

La rééducation de la parole est le traitement le plus couramment prescrit aux personnes atteintes d'aphasie de Broca. En dépit de son efficacité, la rééducation de la parole est un traitement coûteux en termes de temps, argent et ressources humaines. Cela la rend indisponible à un grand nombre de personnes souffrant de l'aphasie de Broca.

L'utilisation des techniques basées sur le traitement automatique du langage pour améliorer la qualité de vie de ses individus est une voie d'exploration émergente qui a reçu beaucoup d'attention par les chercheurs pendant les années dernières.

Dans ce projet de fin d'études, nous nous intéressons à l'utilisation de la traduction automatique et la reconnaissance automatique de la parole pour automatiser une partie de la procédure de réhabilitation des personnes touchées par l'aphasie de Broca.

Dans ce but, menons une étude bibliographique dans laquelle nous introduisons l'aphasie de Broca, ses causes, ses effets, les problèmes avec les traitements classiques et les travaux existant sur la traduction automatique et la reconnaissance automatique de la parole.

Ensuite, nous proposons un système qui combine un modèle de traduction automatique avec un de reconnaissance automatique de la parole pour corriger la parole aphasique en français et nous réalisons le premier de ses modèles. Enfin, nous présentons les résultats de notre travail sous forme d'un corpus de reconnaissance automatique de la parole et d'un modèle de traduction d'un score BLEU de 79.61%.

---

**Mots clés** — Aphasie de Broca, Apprentissage automatique, Traitement automatique du langage, Traduction automatique, Reconnaissance automatique de la parole, Transformeur.

---

## Abstract

Aphasia is a language disorder caused by brain damage (most commonly a stroke). Broca's aphasia is a form of aphasia that impairs language production. It is caused by an injury to Broca's Area, an area of the frontal lobe of the brain; responsible for language decoding. A person suffering from Broca's aphasia may find it difficult to articulate words and sentences. However, they generally can understand what is said to them. This form of aphasia is associated with a lower quality of life and a higher risk of depression and suicide.

Speech therapy is the most commonly prescribed remedy to people with Broca's aphasia. Despite its effectiveness, it remains an expensive, time-consuming, and effort-heavy process. This makes it inaccessible to a significant number of people with aphasia.

The use of natural language processing-based techniques to improve these people's quality of life is an emerging research avenue that has enjoyed the attention of many researchers in recent years.

In this graduation project, we are interested in the use of machine translation and automatic speech recognition to partially automate the rehabilitation of people with aphasia.

To this end, we conduct a bibliographical study in which introduce aphasia, its causes, consequences, the problems of classical treatment methods, and a literature review the existing works pertaining to machine translation and automatic speech recognition.

We then design a system that corrects french aphasic speech by combining a translation model with a speech recognition model, the former of which we implement. We finish by presenting the results of our work: a corpus for automatic speech recognition, and a translation model with a BLEU score of 79.61%.

---

**Keywords** — Broca aphasia, Machine learning, Natural language processing, Machine translation, Automatic speech recognition, Transformer.

---

## ملخص

الحبسة إضطرابٌ لغوي ناتج عن تلف في الدماغ، غالبا نتيجة سكتة دماغية. حبسة بروكا حبسة تنتج عن إصابة في منطقة بروكا، وهي منطقة في الفص الجبهي الأيسر للدماغ تعنى بإنتاج الكلام. قد يجد المصاب بحبسة بروكا صعوبة في تكوين الجمل والكلمات، إلا أنه عادة يفهم ما يقال. ترتبط هذه الحبسة بتدني مسوى العيش وارتفاع خطر الاكتئاب والانتحار.

علاج النطق هو أكثر العلاجات وصفا للمصابين بحبسة بروكا. رغم نجاعته، فهو يظل مكلفا للوقت والمال والجهد، ما يحول دون توفره لعدد كبير ممن يحتاجونه.

توظيف تقنيات معالجة اللغة الطبيعية لتحسين حياة المصابين بحبسة بروكا مجال بحث حظي باهتمام العديد من الباحثين في الأعوام الأخيرة.

في مشروع التخرج هذا، نهتم باستعمال الترجمة الآلية والتعرف الآلي على الكلام لتأدية جزء من علاج النطق لحبسة بروكا أوتوماتيكيا. من أجل ذلك، نعرض دراسة بيبليوغرافية نعرف فيها نعرف فيها بحبسة بروكا أسبابا ونتائج، ثم نتطرق لعيوب العلاجات المعتادة. وللأعمال التي سبق إنجازها في مجالي الترجمة الآلية والتعرف الآلي على الكلام.

نأتي بعدها إلى تصميم نظام لتصحيح الكلام المحتبس باللغة الفرنسية يجمع بين نموذجين، أحدهما للتعرف الآلي على الكلام والآخر للترجمة الآلية ونعرض إنجاز هذا الأخير. نختم أخيرا بعرض نتائج هذا العمل متمثلة في مجموعة بيانات للتعرف الآلي على الكلام ونموذج للترجمة الآلية تقيمه بمقياس BLEU يساوي 79.61% .

---

**الكلمات المفتاحية –** حبسة بروكا، تعلم الآلة، معالجة اللغة الطبيعية، ترجمة آلية، تعرف آلي على الكلام، شبكة عصبية غير ترتيبية.

---

# Table des matières

Page de garde

Résumé i

Abstract ii

ملخص iii

Table des matières iv

Table des figures v

Algorithmes et extraits de code vi

Sigles et abréviations vii

# Table des figures

# Table des matières

# Sigles et abréviations

API	interface de programmation d'application
ASR	reconnaissance automatique de la parole
AVC	<u>a</u> ccident <u>v</u> asculaire <u>c</u> érébral
BART	bidirectional auto-regressive transformer
BERT	bidirectional encoder representations from transformers
BLEU	bilingual evaluation understudy
BPE	byte pair encoding
BPTT	rétro-propagation dans le temps
CLM	modélisation causale du langage
CNN	réseau de neurones à convolutions
DL	apprentissage profond
FFN	réseau de neurones feed-forward
GPT	generative pre-trained transformer
GRU	gated recurrent unit
IL	interlingue
LC	langage cible
LLM	grand modèle de langage
LS	langue source
LSTM	<u>l</u> ong <u>s</u> hort- <u>t</u> erm <u>m</u> emory
ML	apprentissage automatique
MLM	modélisation masquée du langage
MLOps	<u>M</u> achine <u>L</u> earning <u>O</u> perations
MLP	perceptron multicouches
MT	traduction automatique
NLP	traitement automatique du langage
NMT	traduction automatique neuronale
NSP	prédiction de la prochaine phrase



RMBT	traduction automatique à base de règle
RNN	réseau de neurones récurrent
S2S	séquence-à-séquence
SMT	traduction automatique statistique