République Algérienne Démocratique et Populaire

الجمهورية الجزائرية الديموقراطية الشعبية

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

وزارة التعليم العالي والبحث العلمي



المدرسة الوطنية للإعلام الآلي (المعهد الوطني للتكوين في الإعلام الآلي سابقا) École nationale Supérieure d'Informatique ex. INI (Institut National de formation en Informatique)

Mémoire de fin d'études

Pour l'obtention du diplôme d'Ingénieur d'État en Informatique

Option: Systèmes Informatiques

Création d'un corpus de l'aphasie de Broca et développement d'un système Speech-to-speech de réhabilitation de la parole

Réalisé par :
BELGOUMRI Mohammed
Djameleddine
im_belgoumri@esi.dz

Encadré par :
Pr. SMAILI Kamel
smaili@loria.fr
Dr. LANGLOIS David
david.langlois@loria.fr
Dr. ZAKARIA Chahnez
c_zakaria@esi.dz

Table des matières

Page de garde								
Ta	Γable des matières							
Ta	Table des figures							
Li	Liste des algorithmes							
Sigles et abréviations								
1	Réa	lisation	1					
	1.1	Outils et technologies	1					
	1.2	Création des corpus	5					
$\mathbf{R}^{:}$	Rihliographie							

Table des figures

1.1	Composantes	de la	bibliothèa	ue lightning.												4
T • T	Composanics	ac ra	DIDITOUTCG	ac righthing.	•	•		•	•	•	•	•	•	•	•	

Liste des algorithmes

Sigles et abréviations

API interface de programmation d'application

BLEU bilingual evaluation understudy

CNN réseau de neurones à convolutions

DL apprentissage profond

GPT generative pre-trained transformer

 $\begin{array}{ll} \mathrm{ML} & \mathrm{apprentissage\ automatique} \\ \mathrm{MLOps} & \underline{\mathrm{M}}\mathrm{achine}\ \underline{\mathrm{L}}\mathrm{earning\ Operations} \end{array}$

RNN réseau de neurones récurrent

Chapitre 1

Réalisation

Dans le chapitre précédent, nous avons présenté les détails fonctionnels de la conception de notre solution. Le présent chapitre est consacré à la réalisation de cette dernière. Nous commençons par présenter les outils et technologies utilisés pour sa mise en place. Ensuite, nous présentons dans le détail les points importants de l'implémentation des différentes étapes de cette solution.

1.1 Outils et technologies

La création d'un système aussi sophistiqué que le nôtre est une tâche assez complexe. Elle comporte plusieurs étapes dont certaines nécessite d'entraîner des réseaux de neurones ou de faire appel à des réseaux de neurones pré-entraînés par le biais d'interfaces de programmation d'application (API, de l'anglais : application programming interface). Pour faciliter certaines de ces étapes, nous avons exploité plusieurs outils et technologies open-source. Cette section est consacrée à la présentation de ces derniers.

1.1.1 Python

Python est un langage de programmation open-source interprété, orienté objet et multiparadigme. Introduit 1991 par Guido van Rossum (« About Python », 2022), Python est aujourd'hui l'un des langages de programmation les plus populaires au monde. Le (« Stack Overflow Developer Survey », 2022) l'a classé comme la 4° technologie la plus populaire au monde (48.07%) et la 6° technologie la plus aimée (67.34%). La documentation officielle de Python le décrit comme suit :



"Python est un langage de programmation puissant et facile à apprendre. Il dispose de structures de données de haut niveau et permet une approche simple, mais efficace de la programmation orientée objet. Parce que sa syntaxe est élégante, que son typage est dynamique et qu'il est interprété, Python est un langage idéal pour l'écriture de scripts et le développement rapide d'applications dans de nombreux domaines et sur la plupart des plateformes."

— « Le tutoriel Python », 2023

La popularité de Python fait qu'il y a une grande communauté de développeurs qui contribuent à son écosystème. En effet, le répoertoire officiel de Python contient plus de 450 000 packages. Tous les programmes écrits dans le cadre de ce projet sont écrits en Python.

1.1.2 Jupyter

Jupyter est un environnement d'exécution interactif pour Python (et plusieurs autres langages). Il permet de créer des documents appelés "notebooks" qui combine le code exécutable avec une documentation textuelle. Cela est réalisé en divisant le document en unités appelées des "cellules". Une cellule est associée à un langage qui peut-être écrit dedans. Si ce langage est un langage de programmation (Python, R ou Julia), la cellule est exécutable. Si ce langage est Markdown, elle ne l'est pas.



1.1.3 Google Colaboratory, Kaggle et Paperspace Gradient

Colaboratory est un service fourni par Google. Il donne à ses utilisateurs l'accès à un environnement d'exécution Jupyter hébergé sur le cloud. Il est possible d'y créer et d'y exécuter des notebooks sans installation ni configuration. Il offre également (et gratuitement) le choix entre les exécuter sur un CPU ou un GPU. La machine virtuelle qui héberge cet environnement est réinitialisée après 12 h. Cette limite peut être étendue en utilisant un compte payant.



Kaggle est une plateforme en ligne qui permet d'organiser des compétitions en data science. Dans ce cadre, elle donne accès à un environnement similaire à celui trouver sur Google Colaboratory. Les GPU qu'elle offre ont 16 Go de mémoire. Le temps de calcul sur Kaggle est limité à 30 heures par semaine.



Paperspace est une plateforme du calcul cloud dédié au apprentissage automatique (ML, de l'anglais : machine learning) et à l'intelligence artificielle. Elle permet de créer des machines virtuelles avec des configurations personnalisées. Paperspace possède une grande variété d'architectures matérielles. Des CPU et des GPU y sont disponibles, mais aussi des TPU et des IPU. Il est possible de personnaliser le nombre de CPU, GPU, TPU

et IPU à inclure dans une machine, ainsi que le type et les caractéristiques des CPU et GPU.

Gradient est un service offert par Paperspace. Similairement à Google Colaboratory et Kaggle, il permet d'accéder à un environnement Jupyter hébergé sur le cloud. Cependant, il offre plus de flexibilité que ces derniers. Il permet de personnaliser d'une manière similaire aux machines virtuelles de Paperspace.



1.1.4 Anaconda

Anaconda est une distribution logicielle open-source qui regroupe Python, R et une multitude de leurs packages consacrés au calcul scientifique et aux data science. Anaconda permet de créer des environnements virtuels pour Python pour isoler les dépendances entre les projets. Chaque environnement possède sa propre installation de Python et de ses packages. Un gestionnaire de packages appelé "conda" est fourni comme alternative à pip.



1.1.5 CUDA

CUDA est une technologie de calcul parallèle développée par NVI-DIA. Elle permet d'utiliser les GPU de NVIDIA pour accélérer les calculs parallélisables. CUDA est programmable en C++. Cependant, il existe des bibliothèques qui permettent de l'utiliser avec d'autres langages (y compris Python).



1.1.6 PyTorch

PyTorch est une bibliothèque open-source de apprentissage profond (DL, de l'anglais : deep learning) pour Python. Elle permet de créer et d'entraîner rapidement et facilement des réseaux de neurones. Elle est développée par Facebook AI, mais elle fait rejoint la fondation Linux en 2022.

PyTorch possède plusieurs modules. Les plus importants sont :

- torch. Tensor : ce module fournit une implémentation du tenseur, un tableau multidimensionnel qui peut être manipulé mathématiquement d'une façon qui généralise les scalaires, les vecteurs et les matrices.
- torch.nn: ce module contient une implémentation des réseaux de neurones. La classe la plus importante dans ce module est torch.nn.Module. Il s'agit d'une classe abstraite qui doit être



héritée pour créer un réseau de neurones. Des implémentations pour les architectures les plus courantes sont fournies dans ce module (réseau de neurones à convolutions (CNN, convolutional neural network), réseau de neurones récurrent (RNN, de l'anglais : recurrent neural network), transformeur, etc.).

- torch.optim: ce module offre un ensemble d'algorithmes d'optimisation.
- torch.autograd : ce module fournit une implémentation de la dérivation automatique (backward). Il permet de calculer les gradients des paramètres en construisant un graphe de calcul puis en le traversant pour évaluer les dérivées.

Toutes les opérations de PyTorch peuvent être exécutées sur un GPU en utilisant CUDA. Cela rend très rapide l'entraînement des réseaux de neurones.

L'écosystème de PyTorch est très riche. Plusieurs packages sont construits là-dessus par la communauté ainsi que par l'équipe de PyTorch. Parmi les packages torchtext et torchdata nous sont les plus utiles. Le premier nous offre des objets utiles pour le traitement de texte en langage naturel (tokeniseurs, jeux de données populaires, modèles de langage, etc.). Le second implémente les fonctionnalités de manipulation de données. Les deux classes les plus importantes dans ce module sont torchdata. Dataset et torchdata. DataLoader.

1.1.7 Lightning

Lightning. AI est une plateforme pour créer, entraîner et déployer des modèles de DL. La bibliothèque lightning distribuée contient 3 packages (voir Figure 1.1) :

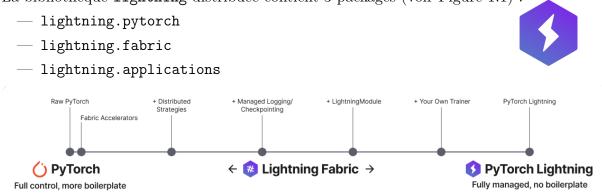


FIGURE 1.1 – Composantes de la bibliothèque lightning (FALCON & THE PYTORCH LIGHTNING TEAM, 2019).

lightning.pytorch (aussi appelé pytorch-lightning) est le seul que nous avons utilisé. Il permet d'étendre PyTorch pour faciliter la création et l'entraînement des modèles. Les fonctionnalités qu'il offre incluent les rappels de fonctions et la journalisation.

Lightning. AI distribue un quatrième package en dehors de la bibliothèque lightning : torchmetrics. Ce dernier implémente plus de 90 métriques d'évaluation, dont l'exactitude

et le score bilingual evaluation understudy (BLEU). Nous avons fait usage de ce package pour calculer ces métriques.

1.1.8 Weights & Biases

Weights & Biases est une plateforme de Machine Learning Operations (MLOps). Son but est de faciliter le processus de développement de journalisation des expériences, de gestion des versions de jeux de données et de collaboration entre les membres d'une équipe.

l'API de Weights & Biases est accessible via un module Python wandb ou via une interface en ligne de commande du même nom. Elle offre la possibilité de journaliser les métriques d'évaluation, les hyperparamètres, les graphes de calcul, etc. Elle est intégrée avec lightning à travers la classe lightning.pytorch.loggers.WandbLogger.



1.1.9 Hugging Face

Hugging Face est une entreprise qui se spécialise en intelligence artificielle. Elle distribue gratuitement plusieurs bibliothèques open-source et des modèles pré-entraînés.

Parmi ces bibliothèques, nous avons utilisé tokenizers qui permet de créer des tokeniseurs et evaluate qui implémente plusieurs métriques d'évaluation (dont la perplexité). Nous l'avons utilisé plutôt que torchmetrics, car elle permet d'utiliser les modèles pré-entraînés dans Hugging Face Hub.



1.1.10 Open AI

Open AI est une entreprise de recherche en intelligence artificielle. C'est cette entreprise qui a créé les modèles generative pre-trained transformer (GPT) et WHISPER discutés dans le chapitre ??.

Nous avons fait appel à l'API de Open AI pour utiliser ChatGPT, une version de GPT-3 qui est entraînée sur des conversations. Nous l'avons utilisé pour générer les erreurs synthétiques. Nous avons également utilisé WHISPER pour la transcription des vidéos collectées, mais nous l'avons utilisé localement, car il est open-source.



1.2 Création des corpus

Bibliographie

About Python. (2022). https://pythoninstitute.org/about-python
FALCON, W., & THE PYTORCH LIGHTNING TEAM. (2019). PyTorch Lightning (Version 1.4). https://doi.org/10.5281/zenodo.3828935
Le tutoriel Python. (2023). https://docs.python.org/3/tutorial/index.html
Stack Overflow Developer Survey. (2022). https://survey.stackoverflow.co/2022/?utm_source=social-share&utm_medium=social&utm_campaign=dev-survey-2022